

Trade-off between Privacy and Utility in Gradient Defenses against Inversion Attacks under a Single-Client Protocol

Niege Marryany dos Reis da Silva¹, Rodrigo Cesar Pedrosa Silva¹

Universidade Federal de Ouro Preto, Brazil

`niege.silva@aluno.ufop.edu.br`

`rodrigo.silva@ufop.edu.br`

Abstract. Gradient inversion attacks reconstruct private training data from gradients shared in federated learning. Under a single-client factorial protocol spanning three image datasets, three architectures, five defense mechanisms and two batch sizes, differential privacy via DP-SGD yields the highest reconstruction error (mean MSE 0.865) but reduces test accuracy to 0.153, a 75% drop relative to the undefended baseline. Random- k sparsification at 10% retention achieves the most favorable privacy-utility balance on CIFAR-10, raising MSE by up to 3.1-fold on Vision Transformers while preserving test accuracy within 0.3 percentage points on ViT (CNN incurs an $\approx 8\%$ drop). Top- k sparsification at the same retention rate does not significantly increase reconstruction error against the iDLG attack ($p > 0.05$) and leaves label inference at 100% accuracy. Defense effectiveness depends critically on dataset complexity, model architecture and compression parameters, limiting generalization from simple benchmarks such as MNIST.

CCS Concepts: • **Computing methodologies** → *Neural networks; Distributed artificial intelligence*; • **Security and privacy** → **Privacy-preserving protocols**.

Keywords: differential privacy, federated learning, gradient compression, gradient inversion attacks, privacy and security in data mining

1. INTRODUÇÃO

O aprendizado federado permite treinar modelos de aprendizado de máquina a partir de dados distribuídos, sem centralizar amostras sensíveis [McMahan et al. 2017]. Em cada rodada de treinamento, clientes calculam gradientes locais e os compartilham com um servidor agregador. Esse fluxo reduz a exposição direta dos dados, mas não elimina riscos de privacidade. Ataques de inversão de gradientes demonstram que informações sobre amostras de treinamento podem ser reconstruídas a partir dos gradientes compartilhados [Zhu et al. 2019; Geiping et al. 2020].

Duas famílias de técnicas são frequentemente empregadas como mecanismos de defesa nesse contexto. A primeira baseia-se em privacidade diferencial, com destaque para métodos que recortam gradientes e adicionam ruído gaussiano antes do compartilhamento [Abadi et al. 2016]. A segunda emprega compressão ou esparsificação de gradientes, transmitindo apenas parte da informação original por meio de técnicas como Top- k , Random- k e quantização estocástica [Stich et al. 2018; Wangni et al. 2018; Alistarh et al. 2017]. Essas abordagens reduzem o volume de comunicação e, em princípio, limitam a quantidade de informação disponível para reconstrução.

Apesar da diversidade de mecanismos descritos na literatura, comparações empíricas sistemáticas permanecem limitadas. Muitos estudos avaliam defesas de forma isolada, com datasets, arquiteturas ou protocolos de ataque distintos. A ausência de um protocolo experimental comum dificulta a identificação de configurações que equilibrem proteção contra inversão de gradientes e utilidade do modelo treinado.

Copyright©2025 Permission to copy without fee all or part of the material printed in KDMiLe is granted provided that the copies are not made or distributed for commercial advantage, and that notice is given that copying is by permission of the Sociedade Brasileira de Computação.

Este trabalho investiga empiricamente o trade-off entre privacidade e utilidade em cinco mecanismos de defesa aplicados durante o treinamento com gradientes compartilhados. O protocolo simula um cliente único local, sem agregação FedAvg (Seção 3). O estudo considera três bases de dados (MNIST, Fashion-MNIST e CIFAR-10), três arquiteturas (MLP, CNN e ViT), cinco defesas (sem defesa, Top- k , DP-SGD, Random- k e QSGD) e dois tamanhos de *batch* (1 e 32). A privacidade é medida pelo erro quadrático médio (MSE) de reconstrução obtido por ataque iDLG, complementado pela taxa de acerto do rótulo inferido. A utilidade é medida pela acurácia no conjunto de teste após uma época de treinamento com defesa aplicada aos gradientes.

A hipótese central é que mecanismos que reduzem a informação contida nos gradientes compartilhados elevam o MSE de reconstrução, com impacto distinto sobre a acurácia do modelo. Os resultados indicam que DP-SGD oferece a maior proteção, porém com queda acentuada de utilidade; Random- k apresenta melhor equilíbrio no CIFAR-10; e Top- k , com taxa de retenção de 10%, não difere estatisticamente do cenário sem defesa nesse dataset.

2. TRABALHOS RELACIONADOS

A literatura sobre privacidade no aprendizado federado divide-se em três eixos convergentes: o compartilhamento de gradientes como vetor de risco, os ataques que exploram esse vetor e os mecanismos de defesa que reduzem a informação transmitida.

2.1 Aprendizado federado e ataques de inversão

O aprendizado federado treina modelos a partir de dados descentralizados, compartilhando apenas atualizações de parâmetros [McMahan et al. 2017]. Gradientes agregados, contudo, podem revelar amostras privadas. O método DLG reconstrói entradas por otimização de gradientes coincidentes [Zhu et al. 2019]; a variante iDLG infere previamente o rótulo, ampliando a taxa de reconstrução [Zhao et al. 2020]. Em cenários com poucos clientes por rodada, gradientes expõem dados mesmo sob condições próximas às de implementações reais [Geiping et al. 2020].

2.2 Mecanismos de defesa

A privacidade diferencial recorta gradientes e adiciona ruído gaussiano (DP-SGD) [Abadi et al. 2016], com variantes federadas no nível do cliente [McMahan et al. 2018] e composição via RDP [Mironov 2017] ou LDP local [Duchi et al. 2013]. Técnicas de compressão retêm Top- k [Stich et al. 2018], Random- k [Wangni et al. 2018] ou quantizam gradientes (QSGD) [Alistarh et al. 2017]; esquemas como SignSGD, TernGrad, DGC e *error feedback* [Bernstein et al. 2018; Wen et al. 2017; Lin et al. 2018; Karimireddy et al. 2019] visam eficiência de comunicação. A proteção contra inversão de gradientes recebe, contudo, tratamento comparativo limitado sob protocolos uniformes.

2.3 Posicionamento deste trabalho

Trabalhos anteriores avaliam cada mecanismo em cenários distintos [Zhu et al. 2019; Geiping et al. 2020; Abadi et al. 2016; Stich et al. 2018; Wangni et al. 2018; Alistarh et al. 2017], sem quantificar o trade-off entre proteção e acurácia em um mesmo protocolo. Este estudo compara empiricamente cinco configurações — sem defesa, Top- k , DP-SGD, Random- k e QSGD — sobre três bases, três arquiteturas e dois tamanhos de *batch*, com iDLG como protocolo de avaliação. Técnicas como Client-Level DP, LDP, SignSGD, TernGrad, DGC e *error feedback* permanecem fora do escopo experimental.

Table I. Grade experimental.

Fator	Níveis	Cardinalidade
Arquitetura	MLP, CNN, ViT	3
Base de dados	MNIST, Fashion-MNIST, CIFAR-10	3
Defesa	<i>none</i> , Top- <i>k</i> , DP-SGD, Random- <i>k</i> , QSGD	5
Tamanho de <i>batch</i>	1, 32	2
Combinações	—	90
Repetições por combinação	—	30
Execuções totais	—	2.700

3. METODOLOGIA EXPERIMENTAL

Esta seção descreve o protocolo empírico empregado para comparar mecanismos de defesa contra inversão de gradientes. O desenho experimental busca manter constantes o ataque, o otimizador e o número de repetições, variando apenas a defesa, a arquitetura, a base de dados e o tamanho do *batch*.

3.1 Desenho experimental

O experimento segue um esquema fatorial completo com quatro fatores: arquitetura (MLP, CNN, ViT), base de dados (MNIST, Fashion-MNIST, CIFAR-10), mecanismo de defesa (sem defesa, Top-*k*, DP-SGD, Random-*k*, QSGD) e tamanho de *batch* (1 e 32). Cada combinação foi executada 30 vezes com *seeds* distintas, totalizando 2.700 execuções de treinamento. A Tabela I resume os fatores e os níveis considerados.

3.2 Bases de dados e arquiteturas

Foram utilizados três conjuntos de imagens com normalização padrão por canal: MNIST e Fashion-MNIST (28×28 , escala de cinza) e CIFAR-10 (32×32 , três canais). O treinamento empregou subconjuntos de 4.000 amostras de treino e 1.000 de teste por execução, visando viabilizar a grade completa em tempo computacional razoável.

Três arquiteturas de classificação foram implementadas. O MLP possui duas camadas ocultas (512 e 256 unidades) sobre entrada achatada. A CNN contém duas camadas convolucionais (32 e 64 filtros) com *max-pooling* e classificador denso. O ViT (*Vision Transformer*) compacto emprega *patches* de 4×4 , dimensão de *embedding* 128, profundidade 4 e 4 *heads* de atenção. A escolha de arquiteturas distintas permite verificar se a eficácia das defesas depende da capacidade representacional do modelo.

3.3 Treinamento e mecanismos de defesa

Cada execução treina o modelo por uma época com otimizador Adam ($\eta = 10^{-3}$). O protocolo simula um **cliente único**: não há agregação FedAvg nem múltiplos participantes por rodada. A defesa é aplicada aos gradientes imediatamente após `loss.backward()`, antes de `optimizer.step()`; os gradientes defendidos substituem os originais em `param.grad`. Os cinco mecanismos avaliados, com parâmetros fixos, são:

- Sem defesa (*none*):** gradientes compartilhados sem alteração, servindo como linha de base.
- Top-*k*:** retenção dos 10% dos componentes de maior magnitude absoluta; demais coordenadas zeradas [Stich et al. 2018].
- Random-*k*:** seleção aleatória de 10% das coordenadas, mantendo apenas esses valores [Wangni et al. 2018].

- DP-SGD**: recorte global por norma L2 ($C = 1,0$) seguido de ruído gaussiano com desvio $\sigma = 1,0 \cdot C$ [Abadi et al. 2016]; o parâmetro σ foi fixado para comparação empírica, **sem reporte de garantia formal** (ε, δ).
- QSGD**: quantização estocástica com 16 níveis discretos [Alistarh et al. 2017].

A taxa de retenção de 10% em Top- k e Random- k define a *taxa de compressão* como 90% de coordenadas descartadas. Modelos treinados são persistidos como *checkpoints* para o ataque de reconstrução.

3.4 Protocolo de ataque

A privacidade foi avaliada por meio do ataque iDLG [Zhao et al. 2020], combinado com *gradient matching* por otimização. Para cada amostra-alvo, o rótulo é inferido a partir do gradiente da camada de saída (heurística iDLG). Em seguida, uma imagem sintética é otimizada para minimizar a distância L2 entre os gradientes do modelo e os gradientes originais da amostra-alvo, com L-BFGS (500 iterações para MLP e CNN; 150 para ViT).

A avaliação de reconstrução utilizou *checkpoints* treinados com $batch = 32$ e $repeat_id = 0$, aplicando o ataque a 30 amostras estratificadas por classe (três por rótulo). Essa escolha padroniza condições de ataque entre defesas e arquiteturas; o fator $batch = 1$ permanece na grade de treinamento e afeta apenas métricas de utilidade. Quando a otimização L-BFGS não convergiu, a amostra foi excluída; o tamanho efetivo n variou entre 21 e 30 reconstruções por configuração (média 29,4), concentrando-se falhas em Fashion-MNIST e MNIST.

3.5 Métricas

Privacidade. O erro quadrático médio (MSE) de reconstrução foi calculado no espaço normalizado $[0, 1]$ por pixel. Valores maiores de MSE indicam reconstrução menos fiel e, portanto, maior proteção contra o ataque empregado. Registrou-se também a taxa de acerto do rótulo inferido (*label_acc*), definida como a proporção de amostras em que o rótulo estimado pelo iDLG coincide com o rótulo verdadeiro.

Utilidade. A acurácia no conjunto de teste (*test_acc*) ao final da única época de treinamento quantifica o impacto da defesa sobre a capacidade preditiva do modelo. Para cada combinação experimental, reportam-se média e desvio-padrão sobre as 30 repetições.

Análise estatística. Diferenças de MSE entre cada defesa e o cenário sem defesa foram testadas pelo teste t de Welch ($\alpha = 0,05$), com amostras independentes por execução de reconstrução. O tamanho de efeito foi quantificado pelo d de Cohen.

4. RESULTADOS

Os resultados são apresentados com foco no CIFAR-10, base em que a reconstrução sem defesa é mais fácil e a separação entre mecanismos é mais nítida. Em seguida, discute-se o trade-off global entre privacidade e utilidade, o efeito da arquitetura e do tamanho de *batch*, e os padrões observados nas demais bases de dados.

4.1 Desempenho no CIFAR-10

A Tabela II consolida MSE de reconstrução, taxa de acerto de rótulo e acurácia de teste ($batch = 32$) para CNN e ViT no CIFAR-10 ($n = 30$ reconstruções por linha). No MLP, o padrão é análogo: DP-SGD eleva o MSE para 0,306 ($p < 0,001$) com acurácia 0,123. Random- k atinge MSE 0,056 ($p = 6,7 \times 10^{-4}$) com acurácia 0,364. Top- k não difere de *none* ($p > 0,05$).

Table II. Resultados no CIFAR-10, CNN e ViT ($batch = 32$; média $\pm$ desvio-padrão). No CIFAR-10, $n = 30$; em MNIST e Fashion-MNIST, n variou de 21 a 30 por falhas de convergência do L-BFGS.

Arch.	Defesa	MSE	Label acc.	Test acc.
CNN	<i>none</i>	$0,009 \pm 0,005$	100%	$0,426 \pm 0,022$
CNN	Top- k	$0,018 \pm 0,046$	100%	$0,406 \pm 0,018$
CNN	DP-SGD	$0,276 \pm 0,043$	13%	$0,124 \pm 0,021$
CNN	Random- k	$0,086 \pm 0,079$	30%	$0,390 \pm 0,019$
CNN	QSGD	$0,052 \pm 0,046$	87%	$0,333 \pm 0,024$
ViT	<i>none</i>	$0,098 \pm 0,067$	100%	$0,291 \pm 0,023$
ViT	Top- k	$0,126 \pm 0,072$	100%	$0,277 \pm 0,019$
ViT	DP-SGD	$0,298 \pm 0,040$	10%	$0,132 \pm 0,027$
ViT	Random- k	$0,303 \pm 0,019$	23%	$0,290 \pm 0,018$
ViT	QSGD	$0,211 \pm 0,096$	70%	$0,285 \pm 0,017$

No cenário sem defesa, o MSE de reconstrução permanece abaixo de 0,10 para CNN, com acerto de rótulo de 100%. DP-SGD eleva o MSE para a faixa 0,28–0,31 nas três arquiteturas, reduzindo a taxa de acerto de rótulo para 10–20% e a acurácia de teste para 0,12–0,13. Random- k e QSGD ocupam posições intermediárias. Random- k atinge MSE de 0,086–0,303 com queda de acurácia inferior a 8% em relação à linha de base na CNN e no ViT. QSGD eleva o MSE por ≈ 6 vezes em relação a *none* na CNN (0,052 *vs.* 0,009), com redução de acurácia de 22%. Top- k não produz diferença estatisticamente significativa em relação a *none* ($p > 0,05$; teste t de Welch) e mantém acerto de rótulo de 100%. DP-SGD, Random- k e QSGD diferem significativamente de *none* na CNN e no ViT ($p < 0,001$).

4.2 Trade-off privacidade e utilidade

A Figura 1 e a Figura 2 sintetizam o trade-off entre MSE de reconstrução e acurácia de teste. A média das nove combinações arquitetura–dataset ($batch = 32$) por defesa revela três perfis distintos:

- DP-SGD:** MSE médio 0,865 e acurácia 0,153 — máxima proteção, utilidade reduzida em 75% em relação a *none* (0,614).
- Random- k :** MSE 0,696 e acurácia 0,590 — proteção substancial com perda de utilidade de 4%.
- QSGD:** MSE 0,530 e acurácia 0,548 — proteção moderada com perda de 11%.
- Top- k e *none*:** MSE 0,332 e 0,404; acurácia 0,590 e 0,614 — utilidade preservada, proteção limitada ou inexistente.

O valor global de Top- k inferior ao de *none* (0,332 *vs.* 0,404) é explicado pelo comportamento do método em MNIST (Seção 4.4). Nesse dataset, a compressão por magnitude facilita inadvertidamente a otimização do ataque. No CIFAR-10, Top- k não difere estatisticamente de *none* ($p > 0,05$). A média global subestima, portanto, a eficácia relativa dos demais mecanismos em cenários de maior complexidade de imagem.

4.3 Efeito da arquitetura e do tamanho de $batch$

A arquitetura modula a vulnerabilidade base e a resposta às defesas. No CIFAR-10 sem defesa, o MSE de reconstrução do ViT (0,098) supera o da CNN (0,009) e do MLP (0,014), embora a acurácia de teste do ViT (0,291) fique abaixo das demais. Random- k e DP-SGD elevam o MSE do ViT para 0,303 e 0,298, respectivamente.

No CIFAR-10 com CNN, Random- k constitui o melhor equilíbrio observado: MSE 9,5 vezes superior ao de *none* (0,086 *vs.* 0,009) e acurácia de 0,390 (queda de 8%). No ViT, Random- k eleva o MSE de 0,098 para 0,303 com acurácia praticamente inalterada (0,290 *vs.* 0,291). O tamanho de $batch$ afeta





Fig. 1. Trade-off entre MSE de reconstrução e acurácia de teste (médias globais).

Fig. 2. Acurácia de teste por defesa, arquitetura e tamanho de *batch* no CIFAR-10.

predominantemente a utilidade: na CNN, aumentar o *batch* de 1 para 32 eleva a acurácia de *none* de 0,381 para 0,426 (+4,5 pontos percentuais). DP-SGD permanece insensível (0,124 em ambos os tamanhos). QSGD sofre maior penalização com *batch* = 32 (0,333 *vs.* 0,405 com *batch* = 1).

4.4 Resultados em MNIST e Fashion-MNIST

Em MNIST e Fashion-MNIST, a reconstrução sem defesa apresenta MSE elevado e alta variância, dificultando a discriminação entre defesas. No MNIST com MLP, Top-*k*, Random-*k* e QSGD produzem MSE *inferior* ao de *none* ($p < 0,05$), sugerindo que a compressão pode facilitar inadvertidamente a otimização do ataque. Em Fashion-MNIST com CNN, Random-*k* eleva o MSE de 0,36 para 1,59 ($p = 6,3 \times 10^{-10}$), enquanto Top-*k* reduz o MSE para 0,028 ($p = 0,016$).

4.5 Validação da hipótese

A hipótese de que mecanismos que reduzem a informação nos gradientes elevam o MSE de reconstrução é **confirmada parcialmente**. DP-SGD, Random- k e QSGD aumentam significativamente o MSE no CIFAR-10 em pelo menos duas arquiteturas, com trade-offs distintos sobre a acurácia. Top- k , contudo, **não confirma** a hipótese no protocolo empregado: a retenção de 10% dos componentes de maior magnitude não impede o iDLG de inferir rótulos com 100% de acerto. A utilidade do modelo decresce de forma previsível apenas para DP-SGD (queda de $\approx 75\%$) e, em menor grau, para QSGD ($\approx 11\%$) e Random- k ($\approx 4\%$ em média global).

5. CONCLUSÕES

Este estudo comparou empiricamente cinco mecanismos de defesa contra inversão de gradientes em um protocolo fatorial uniforme. Os resultados quantificam o trade-off entre privacidade — medida por MSE de reconstrução e acerto de rótulo via iDLG — e utilidade — medida por acurácia de teste após uma época de treinamento.

DP-SGD produziu a maior proteção em todas as bases e arquiteturas avaliadas, elevando o MSE médio global de 0,404 para 0,865 e reduzindo a acurácia média de 0,614 para 0,153. Random- k emergiu como a alternativa mais equilibrada no CIFAR-10 ($p < 0,001$), com redução de acurácia inferior a 8% na CNN e praticamente nula no ViT. QSGD ocupou posição intermediária (MSE 0,530; acurácia 0,548). Top- k a 10% não diferiu estatisticamente de *none* no CIFAR-10 e manteve acerto de rótulo de 100%. A eficácia das defesas depende da complexidade da base de dados e da arquitetura: o CIFAR-10 permitiu discriminar os mecanismos; em MNIST, a alta variância do MSE de baseline limitou a validade comparativa. O ViT apresentou MSE base de 0,098 (CNN: 0,009; MLP: 0,014); Random- k e DP-SGD elevaram o MSE para 0,303 e 0,298, respectivamente.

5.1 Limitações

O protocolo simulou um cliente único, sem agregação multi-cliente. Empregou uma única época e subconjuntos de 4.000 amostras de treino. A avaliação de privacidade restringiu-se ao iDLG com L-BFGS, em *checkpoints* com $batch = 32$; ataques adaptativos ou múltiplas rodadas federadas podem alterar a eficácia relativa. Os parâmetros de compressão (10%) e de ruído ($\sigma = 1,0$) foram fixos, sem varredura; DP-SGD não reportou garantia (ϵ, δ) . Falhas de convergência do ataque reduziram n a 21–30 por configuração. Por fim, cinco de onze técnicas catalogadas — LDP, RDP, SignSGD, TernGrad e DGC — não foram implementadas.

5.2 Trabalhos futuros

Pesquisas subsequentes podem estender a grade com varredura de taxas de retenção, níveis de ruído e número de épocas. Podem incluir agregação FedAvg, ataques adicionais (DLG, GradInversion) e técnicas não avaliadas. A combinação de compressão aleatória com ruído diferencial constitui candidata natural a investigação futura.

REFERENCES

- ABADI, M., CHU, A., GOODFELLOW, I., McMAHAN, H. B., MIRONOV, I., TALWAR, K., AND ZHANG, L. Deep Learning with Differential Privacy. In *Proceedings of the ACM Conference on Computer and Communications Security*. Vienna, Austria, pp. 308–318, 2016.
- ALISTARH, D., GRUBIC, D., LI, J., TOMIOKA, R., AND VOJNOVIC, M. QSGD: Communication-Efficient SGD via Gradient Quantization and Encoding. In *Proceedings of the Conference on Neural Information Processing Systems*. Long Beach, USA, pp. 1707–1718, 2017.

- BERNSTEIN, J., WANG, Y.-X., LOPEZ-PAZ, D., AND RECHT, B. signSGD: Compressed Optimisation for Non-Convex Problems. In *Proceedings of the International Conference on Machine Learning*. Stockholm, Sweden, pp. 560–569, 2018.
- DUCHI, J. C., JORDAN, M. I., AND WAINWRIGHT, M. J. Local Privacy and Statistical Minimax Rates. In *Proceedings of the IEEE Symposium on Foundations of Computer Science*. Berkeley, USA, pp. 429–438, 2013.
- GEIPING, J., FOWL, L. H., TRAMER, F., FAGHRI, F., CHEN, R. T., GOLDBLUM, M., AND GOLDSTEIN, T. Inverting Gradients – How Easy is it to Break Privacy in Federated Learning? In *Proceedings of the Conference on Neural Information Processing Systems*. Virtual Event, pp. 16937–16947, 2020.
- KARIMIREDDY, S. P., REBJOCK, Q., STICH, S. U., AND JAGGI, M. Error Feedback Fixes SignSGD and other Gradient Compression Schemes. In *Proceedings of the International Conference on Machine Learning*. Long Beach, USA, pp. 3252–3261, 2019.
- LIN, Y., HAN, S., MAO, H., WANG, Y., AND DALLY, W. J. Deep Gradient Compression: Reducing the Communication Bandwidth for Distributed Training. In *Proceedings of the International Conference on Learning Representations*. Vancouver, Canada, pp. 1–14, 2018. ICLR 2018, OpenReview: openreview.net/forum?id=SkhQHMW0W.
- MCMAHAN, H. B., MOORE, E., RAMAGE, D., HAMPSON, S., AND Y ARCAS, B. A. Communication-Efficient Learning of Deep Networks from Decentralized Data. In *Proceedings of the International Conference on Artificial Intelligence and Statistics*. Fort Lauderdale, USA, pp. 1273–1282, 2017.
- MCMAHAN, H. B., RAMAGE, D., TALWAR, K., AND ZHANG, L. Learning Differentially Private Recurrent Language Models. In *Proceedings of the International Conference on Learning Representations*. Vancouver, Canada, pp. 1–14, 2018. ICLR 2018, OpenReview: openreview.net/forum?id=BJ0hF1Z0b.
- MIRONOV, I. Rényi Differential Privacy. In *Proceedings of the IEEE Computer Security Foundations Symposium*. Santa Barbara, USA, pp. 263–275, 2017.
- STICH, S. U., CORDONNIER, J.-B., AND JAGGI, M. Sparsified SGD with Memory. In *Proceedings of the Conference on Neural Information Processing Systems*. Montreal, Canada, pp. 4447–4458, 2018.
- WANGNI, J., WANG, J., LIU, J., AND ZHANG, T. Gradient Sparsification for Communication-Efficient Distributed Optimization. In *Proceedings of the Conference on Neural Information Processing Systems*. Montreal, Canada, pp. 1299–1309, 2018.
- WEN, W., XIE, C., YAN, F., YUAN, C., AND LI, H. TernGrad: Ternary Gradients to Reduce Communication in Distributed Deep Learning. In *Proceedings of the Conference on Neural Information Processing Systems*. Long Beach, USA, pp. 1509–1519, 2017.
- ZHAO, B., MOPURI, K. R., AND BILEN, H. iDLG: Improved Deep Leakage from Gradients. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. Seattle, USA, pp. 14714–14722, 2020.
- ZHU, L., LIU, Z., AND HAN, S. Deep Leakage from Gradients. In *Proceedings of the Conference on Neural Information Processing Systems*. Vancouver, Canada, pp. 14774–14784, 2019.