

# Defesas Contra Gradient Inversion em Federated Learning

## 1 Introdução

Ataques de *gradient inversion* exploram gradientes compartilhados no treinamento distribuído para reconstruir dados de treinamento. Duas famílias de técnicas são frequentemente utilizadas como mecanismos de defesa:

- Privacidade Diferencial
- Compressão ou Esparsificação de Gradientes

Estas técnicas reduzem a quantidade de informação disponível para reconstrução de dados.

## 2 Privacidade Diferencial

### 2.1 DP-SGD

O método mais comum consiste em:

1. recortar o gradiente (*gradient clipping*)
2. adicionar ruído Gaussiano

$$\tilde{g} = \frac{1}{B} \sum_{i=1}^B \text{clip}(g_i, C) + \mathcal{N}(0, \sigma^2 C^2 I)$$

#### Referência

Abadi et al. Deep Learning with Differential Privacy. CCS, 2016.

### 2.2 Client-Level Differential Privacy

Neste caso, o ruído é aplicado ao *update* de cada cliente no treinamento federado.

#### Referência

McMahan et al. Learning Differentially Private Recurrent Language Models. ICLR, 2018.

### 2.3 Rényi Differential Privacy

Utiliza divergência de Rényi para contabilizar perda de privacidade ao longo de múltiplas iterações de treinamento.

#### Referência

Mironov. Rényi Differential Privacy. CSF, 2017.

### 2.4 Local Differential Privacy

Cada cliente adiciona ruído antes de transmitir seu gradiente.

$$\tilde{g}_i = g_i + \mathcal{N}(0, \sigma^2)$$

#### Referência

Duchi, Jordan, Wainwright. Local Privacy and Statistical Minimax Rates. FOCS, 2013.

### 3 Compressão e Esparsificação de Gradientes

Essas técnicas reduzem o volume de comunicação e também removem parte da informação potencialmente explorável por ataques.

#### 3.1 Top-k Sparsification

Somente os  $k$  maiores componentes do gradiente são transmitidos.

$$g'_i = \begin{cases} g_i & i \in \text{Top-}k(|g|) \\ 0 & \text{caso contrário} \end{cases}$$

##### Referência

Stich et al. Sparsified SGD with Memory. NeurIPS, 2018.

#### 3.2 Random-k Sparsification

Seleciona aleatoriamente  $k$  coordenadas do gradiente.

##### Referência

Wangni et al. Gradient Sparsification for Communication-Efficient Distributed Optimization. NeurIPS, 2018.

#### 3.3 SignSGD

Apenas o sinal do gradiente é transmitido.

$$g' = \text{sign}(g)$$

##### Referência

Bernstein et al. signSGD: Compressed Optimisation for Non-Convex Problems. ICML, 2018.

#### 3.4 TernGrad

Gradientes são quantizados em três níveis.

$$g' \in \{-1, 0, 1\}$$

##### Referência

Wen et al. TernGrad: Ternary Gradients to Reduce Communication in Distributed Deep Learning. NeurIPS, 2017.

#### 3.5 QSGD

Gradientes são quantizados em múltiplos níveis discretos.

##### Referência

Alistarh et al. QSGD: Communication-Efficient SGD via Gradient Quantization. NeurIPS, 2017.

#### 3.6 Deep Gradient Compression

Combina:

- esparsificação
- correção de momentum
- acumulação local

##### Referência

Lin et al. Deep Gradient Compression. ICLR, 2018.

#### 3.7 Error Feedback Compression

O erro de compressão é acumulado e reintroduzido nas iterações seguintes.

##### Referência

Karimireddy et al. Error Feedback Fixes SignSGD. ICML, 2019.