

UNIVERSIDADE FEDERAL DE OURO PRETO
INSTITUTO DE CIÊNCIAS EXATAS E BIOLÓGICAS
DEPARTAMENTO DE COMPUTAÇÃO

NIEGE MARRYANY DOS REIS DA SILVA
Orientador: Prof. Dr. Rodrigo Cesar Pedrosa Silva

**COMPROMISSO ENTRE PRIVACIDADE E UTILIDADE EM DEFESAS
CONTRA ATAQUES DE INVERSÃO DE GRADIENTES
INTRODUÇÃO**

Ouro Preto, MG
2026

UNIVERSIDADE FEDERAL DE OURO PRETO
INSTITUTO DE CIÊNCIAS EXATAS E BIOLÓGICAS
DEPARTAMENTO DE COMPUTAÇÃO

NIEGE MARRYANY DOS REIS DA SILVA

**COMPROMISSO ENTRE PRIVACIDADE E UTILIDADE EM DEFESAS CONTRA
ATAQUES DE INVERSÃO DE GRADIENTES**

INTRODUÇÃO

Introdução da Monografia I apresentada ao Curso de Ciência da Computação da Universidade Federal de Ouro Preto como parte dos requisitos necessários para a obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Prof. Dr. Rodrigo Cesar Pedrosa Silva

Ouro Preto, MG
2026

Sumário

1	Introdução	1
1.1	Objetivos	3
	Referências	5

1 Introdução

Modelos de aprendizado de máquina fazem parte de um número crescente de aplicações cotidianas. Teclados de celulares sugerem a próxima palavra a ser digitada, plataformas de vídeo recomendam conteúdos com base no histórico de cada usuário e sistemas de apoio ao diagnóstico analisam exames de imagem em hospitais. Em comum, essas aplicações dependem de grandes volumes de dados para atingir bom desempenho, e esses dados frequentemente contêm informações pessoais e sensíveis, como mensagens privadas, fotografias e registros clínicos (Goodfellow; Bengio; Courville, 2016).

No treinamento convencional, todos os dados são reunidos em um servidor central, onde o modelo é ajustado. Essa centralização traz dois problemas. O primeiro é o risco de vazamento: um único servidor que armazena dados de milhões de pessoas torna-se um alvo valioso para ataques. O segundo é de ordem legal e institucional, pois muitas organizações não podem, ou não desejam, transferir os dados de seus usuários para terceiros. Um hospital, por exemplo, dificilmente pode enviar prontuários de pacientes para ser processados fora de sua infraestrutura.

O aprendizado federado surgiu como uma alternativa a esse modelo centralizado (McMahan et al., 2017). Nele, diversos participantes, chamados de clientes, colaboram para treinar um modelo comum sem compartilhar seus dados brutos. Uma analogia útil é a de vários hospitais que desejam construir juntos um modelo de apoio ao diagnóstico. Em vez de enviar os prontuários de seus pacientes a uma central, cada hospital treina o modelo localmente com seus próprios dados e envia apenas as lições aprendidas, isto é, os ajustes que sugere aos parâmetros do modelo. Um servidor combina esses ajustes e devolve aos hospitais uma versão aprimorada do modelo, repetindo o processo por várias rodadas.

Os ajustes enviados pelos clientes são, em geral, gradientes. O gradiente indica em que direção cada parâmetro do modelo deve ser alterado para reduzir o erro nas amostras de treinamento do cliente. Na forma mais simples do aprendizado federado, o servidor atualiza o modelo combinando os gradientes recebidos da seguinte maneira:

$$w_{t+1} = w_t - \eta \sum_{k=1}^M \frac{n_k}{n} g_k \quad (1.1)$$

em que w_t representa os parâmetros do modelo na rodada t , η é a taxa de aprendizado, M é o número de clientes, n_k é a quantidade de amostras do cliente k , n é o total de amostras e g_k é o gradiente calculado pelo cliente k sobre seus dados locais. A Equação 1.1 evidencia que o servidor nunca recebe as amostras em si, apenas os vetores g_k . A premissa implícita do aprendizado federado é que esses vetores contêm menos informação sobre os dados do que os próprios dados.

Essa premissa, contudo, mostrou-se frágil. Voltando à analogia, é como se, a partir apenas dos ajustes enviados por um hospital, fosse possível reconstruir os prontuários que os originaram. [Zhu, Liu e Han \(2019\)](#) demonstraram exatamente isso em um ataque denominado Deep Leakage from Gradients (DLG). O adversário cria uma imagem aleatória, calcula o gradiente que ela produziria no modelo e a ajusta repetidamente até que esse gradiente coincida com o gradiente compartilhado pelo cliente. Ao final do processo, a imagem artificial torna-se praticamente idêntica à imagem original de treinamento. Trabalhos posteriores tornaram esses ataques, conhecidos como ataques de inversão de gradientes, mais estáveis e eficazes. O iDLG mostrou que o rótulo de uma amostra pode ser extraído diretamente do gradiente, sem nenhuma otimização ([Zhao; Mopuri; Bilen, 2020](#)), e outros métodos obtiveram reconstruções reconhecíveis de imagens de alta resolução e até de lotes com dezenas de imagens ([Geiping et al., 2020](#); [Yin et al., 2021](#)). Compartilhar gradientes, portanto, não equivale a proteger os dados que os geraram.

Para mitigar esse risco, a literatura recorre principalmente a duas famílias de técnicas, que atuam modificando o gradiente antes que ele seja utilizado ou compartilhado. A primeira é a privacidade diferencial, cujo representante mais conhecido no treinamento de redes neurais é o DP-SGD ([Abadi et al., 2016](#)). Esse método limita a influência de cada amostra, recortando os gradientes que ultrapassam uma norma máxima, e em seguida adiciona ruído aleatório, de modo que a contribuição individual de cada dado fique mascarada. A segunda família é a compressão de gradientes, originalmente concebida para reduzir o custo de comunicação em treinamento distribuído. Nas esparsificações Top- k ([Stich; Cordonnier; Jaggi, 2018](#)) e Random- k ([Wangni et al., 2018](#)), apenas uma fração dos valores do gradiente é mantida, escolhida pelas maiores magnitudes ou por sorteio; na quantização QSGD ([Alistarh et al., 2017](#)), todos os valores são mantidos, mas arredondados para poucos níveis possíveis.

Ambas as famílias reduzem a informação disponível ao adversário, mas também alteram a direção em que o modelo é ajustado durante o treinamento. Quanto mais ruído é adicionado ou quanto mais valores são descartados, mais difícil se torna o ataque, porém menor tende a ser a acurácia do modelo final. Estabelece-se, assim, um compromisso entre privacidade e utilidade: uma defesa que protege completamente os dados, mas produz um modelo inútil, não resolve o problema, assim como um modelo excelente que expõe os dados de seus usuários também não é aceitável.

Apesar da diversidade de defesas propostas, comparações empíricas sistemáticas entre elas permanecem escassas. Os trabalhos que introduzem ataques avaliam defesas de forma incidental, geralmente com uma única arquitetura de rede ([Zhu; Liu; Han, 2019](#)). Os trabalhos sobre privacidade diferencial quantificam a perda de acurácia, mas não a resistência empírica a ataques de inversão ([Abadi et al., 2016](#)). As técnicas de compressão, por sua vez, foram avaliadas quanto à economia de comunicação, sem análise de privacidade ([Stich; Cordonnier; Jaggi, 2018](#); [Wangni et al., 2018](#); [Alistarh et al., 2017](#); [Lin et al., 2018](#)). Mesmo as avaliações comparativas existentes concentram-se em arquiteturas convolucionais e em conjuntos específicos de defesas

(Wei et al., 2020; Huang et al., 2021). Como cada estudo emprega bases de dados, arquiteturas e protocolos de ataque distintos, não é possível determinar, a partir da literatura, quais configurações oferecem o melhor equilíbrio entre proteção e desempenho, nem se as conclusões obtidas em um cenário se mantêm em outro.

Diante desse cenário, este trabalho busca responder à seguinte questão: sob um mesmo protocolo experimental, qual é o compromisso entre privacidade e utilidade proporcionado por mecanismos de ruído e de compressão de gradientes contra ataques de inversão, e como esse compromisso varia de acordo com a base de dados, a arquitetura do modelo e o tamanho do lote de treinamento?

Dessa questão derivam três hipóteses, formuladas de modo que possam ser aceitas ou rejeitadas a partir dos dados:

- H1: mecanismos que reduzem a informação contida no gradiente elevam o erro de reconstrução obtido pelo ataque em relação ao cenário sem defesa;
- H2: esse ganho de proteção é acompanhado de perda de acurácia, e a magnitude dessa perda difere conforme a natureza da redução aplicada, seja ela a adição de ruído, o descarte de valores ou a perda de precisão numérica;
- H3: a eficácia de uma mesma defesa varia com a base de dados e com a arquitetura, de modo que conclusões obtidas em uma configuração não se transferem automaticamente para outra.

1.1 Objetivos

O objetivo geral deste trabalho é avaliar empiricamente o compromisso entre privacidade e utilidade de um mecanismo de recorte e ruído inspirado no DP-SGD e de três mecanismos de compressão de gradientes diante de ataques de inversão, sob um protocolo experimental uniforme. Especificamente, pretende-se:

- quantificar o efeito de cada defesa sobre o erro de reconstrução e sobre a acurácia de inferência de rótulo obtidos pelo ataque iDLG;
- quantificar o custo que cada defesa impõe à utilidade do modelo, medida pela acurácia no conjunto de teste;
- determinar quais dessas diferenças são estatisticamente sustentadas, considerando a variabilidade entre execuções e o número de comparações realizadas;
- caracterizar como o compromisso entre privacidade e utilidade depende da base de dados, da arquitetura e do tamanho do lote;

- identificar, segundo um critério definido previamente no Capítulo 3, as configurações que oferecem o melhor equilíbrio entre proteção e desempenho.

As contribuições esperadas são três. A primeira é um protocolo experimental uniforme que permite comparar, nas mesmas condições, defesas originadas de literaturas distintas, a de privacidade e a de eficiência de comunicação. A segunda é a evidência empírica sobre o comportamento dessas defesas em três arquiteturas com vieses indutivos diferentes, incluindo uma arquitetura baseada em atenção. A terceira é a documentação explícita das condições sob as quais os resultados valem, com as decisões de implementação, as ameaças à validade e os dados brutos registrados, de modo que o estudo possa ser replicado e estendido.

Referências

- ABADI, M.; CHU, A.; GOODFELLOW, I.; MCMAHAN, H. B.; MIRONOV, I.; TALWAR, K.; ZHANG, L. Deep learning with differential privacy. In: *Proceedings of the ACM Conference on Computer and Communications Security*. Vienna: [s.n.], 2016. p. 308–318. Citado na página 2.
- ALISTARH, D.; GRUBIC, D.; LI, J.; TOMIOKA, R.; VOJNOVIC, M. QSGD: Communication-efficient SGD via gradient quantization and encoding. In: *Proceedings of the Conference on Neural Information Processing Systems*. Long Beach: [s.n.], 2017. p. 1709–1720. Citado na página 2.
- GEIPING, J.; BAUERMEISTER, H.; DRÖGE, H.; MOELLER, M. Inverting gradients – how easy is it to break privacy in federated learning? In: *Proceedings of the Conference on Neural Information Processing Systems*. Virtual Event: [s.n.], 2020. p. 16937–16947. Citado na página 2.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge: MIT Press, 2016. Citado na página 1.
- HUANG, Y.; GUPTA, S.; SONG, Z.; LI, K.; ARORA, S. Evaluating gradient inversion attacks and defenses in federated learning. In: *Proceedings of the Conference on Neural Information Processing Systems*. Virtual Event: [s.n.], 2021. p. 7232–7241. Citado na página 3.
- LIN, Y.; HAN, S.; MAO, H.; WANG, Y.; DALLY, W. J. Deep gradient compression: Reducing the communication bandwidth for distributed training. In: *Proceedings of the International Conference on Learning Representations*. Vancouver: [s.n.], 2018. Citado na página 2.
- MCMAHAN, H. B.; MOORE, E.; RAMAGE, D.; HAMPSON, S.; AGÜERA Y ARCAS, B. Communication-efficient learning of deep networks from decentralized data. In: *Proceedings of the International Conference on Artificial Intelligence and Statistics*. Fort Lauderdale: [s.n.], 2017. p. 1273–1282. Citado na página 1.
- STICH, S. U.; CORDONNIER, J.-B.; JAGGI, M. Sparsified SGD with memory. In: *Proceedings of the Conference on Neural Information Processing Systems*. Montreal: [s.n.], 2018. p. 4447–4458. Citado na página 2.
- WANGNI, J.; WANG, J.; LIU, J.; ZHANG, T. Gradient sparsification for communication-efficient distributed optimization. In: *Proceedings of the Conference on Neural Information Processing Systems*. Montreal: [s.n.], 2018. p. 1299–1309. Citado na página 2.
- WEI, W.; LIU, L.; LOPER, M.; CHOW, K.-H.; GURSOY, M. E.; TRUEX, S.; WU, Y. A framework for evaluating client privacy leakages in federated learning. In: *Proceedings of the European Symposium on Research in Computer Security*. Cham: Springer, 2020. (Lecture Notes in Computer Science, v. 12308), p. 545–566. Citado na página 3.
- YIN, H.; MALLYA, A.; VAHDAT, A.; ALVAREZ, J. M.; KAUTZ, J.; MOLCHANOV, P. See through gradients: Image batch recovery via GradInversion. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Virtual Event: [s.n.], 2021. p. 16337–16346. Citado na página 2.

ZHAO, B.; MOPURI, K. R.; BILEN, H. *iDLG: Improved Deep Leakage from Gradients*. 2020. ArXiv:2001.02610. Citado na página [2](#).

ZHU, L.; LIU, Z.; HAN, S. Deep leakage from gradients. In: *Proceedings of the Conference on Neural Information Processing Systems*. Vancouver: [s.n.], 2019. p. 14774–14784. Citado na página [2](#).